B8.1 Faktorizace matic

čtvrtek 21. května 2026 14:02

B8.1 Faktorizace matic a jejich využití v numerické LA

→ základní úlohy numerické lineární algebry
- $Ax = b$
- $Ax = \lambda x$
- $Ax = b$ pro přeurčený systém

LU rozklad

≡ rozklad matice $A = LU$, kde L je ◺ a U je ◹ pomocí Gaussovy eliminace pro $A \in \mathbb{C}^{n \times n}$

→ lze rozepsat pomocí série dolních trojúhelníkových matic, které realizují řádkové úpravy — jejich součin je taky ◺

$$A^{(1)} = L_1 A \,, \text{ kde } \quad L_1 = \begin{bmatrix} 1 & & & 0 \\ -l_{21} & 1 & & \\ \vdots & 0 & \ddots & \\ -l_{n1} & 0 & \cdots & 1 \end{bmatrix} \qquad l_{ij} = \frac{a_{ij}^{(k-1)}}{a_{jj}^{(k-1)}}$$

pro $i > j$

$$\Rightarrow \quad L_{n-1} \cdots L_1 A = U$$
$$A = L_1^{-1} \cdots L_{n-1}^{-1} U$$

Pivotizace

→ rozklad může být nestabilní pro a_{kk} blízko nule

⇒ pivotizace ≡ prohazování řádků, aby na diagonále byl největší element

→ je možná i sloupcová, ale to zvyšuje náročnost metody na $\sim n^3$ oproti řádkové, která je $\sim n^2$

$$L_{n-1} P_{n-1} \cdots L_1 P_1 A = U \xrightarrow{\text{lze přepsat}} \underbrace{L'_{n-1} \cdots L'_1}_{\text{mají přeuspořádané prvky}} \underbrace{P_{n-1} \cdots P_1}_{\text{permutační matici lze uložit jako vektor}} A = U$$

matice prohození sloupců

Algoritmus s řádkovou pivotizací

```
U = A, L = I, P = I
pro k = 1,...,n-1 :
    najdi j ≥ k  max |u_jk|
    prohoď   u_k(k:n) ↔ u_j(k:n)
    prohoď   l_k(1:k-1) ↔ l_j(1:k-1)
    prohoď   p_k(1:n) ↔ p_j(1:n)
    pro j = k+1, n :
        l_jk = u_jk / u_kk
        u_j(k:n) = u_j(k:n) - l_jk u_k(k:n)
```

2 operace

náročnost :

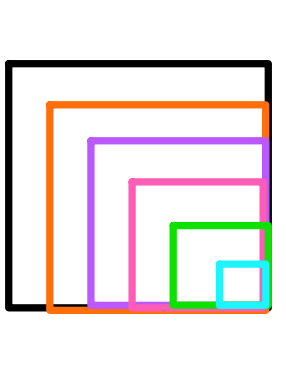

$\frac{1}{3}n^3$

× 2

$\sim \frac{2}{3}n^3$

$$L_k = 1 - \vec{l}_k \vec{e}_k$$
$$L_k^{-1} = 1 + \vec{l}_k \vec{e}_k$$

→ řešení soustavy: $Ax = b \iff PAx = Pb \qquad \overset{U}{\overbrace{L^{-1}PA}}x = L^{-1}Pb$

⇒ řešíme $Ly = Pb \ \wedge \ Ux = y$ → obě $\sim n^2$

⇒ vyplatí se pokud $A = \text{konst.}$ a b se mění

→ bez pivotizace není zpětně stabilní, s pivotizací ano

- bez pivotizace $\tilde{L}\tilde{U} = A + \delta A \qquad \|\delta A\| = \|\tilde{L}\|\|\tilde{U}\| \, \mathcal{O}(\varepsilon_M)$

  spočtené — mohou být obrovské

- s pivotizací $\tilde{L}\tilde{U} = \tilde{P}A + \delta A \qquad \|\delta A\| = \|A\| \, \mathcal{O}(\rho_A \varepsilon_M)$

  $\rho_A = \frac{\max|u_{ij}|}{\max|a_{ij}|} \sim \sqrt{n} \leq 2^n$

  typicky — maximálně

Choleského rozklad

≡ speciální pro A symetrickou pozitivně definitní, pak lze psát
$$A = R^T R,$$
kde R je ◹ s kladnými prvky na diagonále

$$A = \begin{bmatrix} a_{11} & w^+ \\ w & K \end{bmatrix} = \begin{bmatrix} \alpha & 0 \\ \frac{w}{\alpha} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & K - \frac{ww^+}{\alpha^2} \end{bmatrix} \begin{bmatrix} \alpha & \frac{w^+}{\alpha} \\ 0 & 1 \end{bmatrix},$$

kde $\alpha = \sqrt{a_{11}}$

→ potřebujeme spočítat jen 1 matici ⇒ $\sim \frac{1}{3}n^3$

QR rozklad a SVD rozklad a využití při řešení špatně podmíněných úloh a přeurčených soustav

QR rozklad

→ QR rozklad: $A = QR$, kde R je ◹ a Q je ortogonální pro $A^{m \times n}$

myšenka:

$$\left(\vec{a}_1 \middle| \cdots \middle| \vec{a}_n\right) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = x_1 \vec{a}_1 + \cdots x_n \vec{a}_n = \vec{y}$$

chceme přejít k ON bázi v $\vec{y}$ prostoru.

↳ pomocí Gram-Schmidtovy ortogonalizace

$$\left.\begin{aligned} a_1 &= r_{11} q_1 \\ a_2 &= r_{12} q_1 + r_{22} q_2 \\ &\vdots \end{aligned}\right\} \ A = QR$$

→ úplný rozklad ≡ doplníme $\hat{Q}$ do plné matice $n \times n$ a $\hat{R}$ o nulové řádky

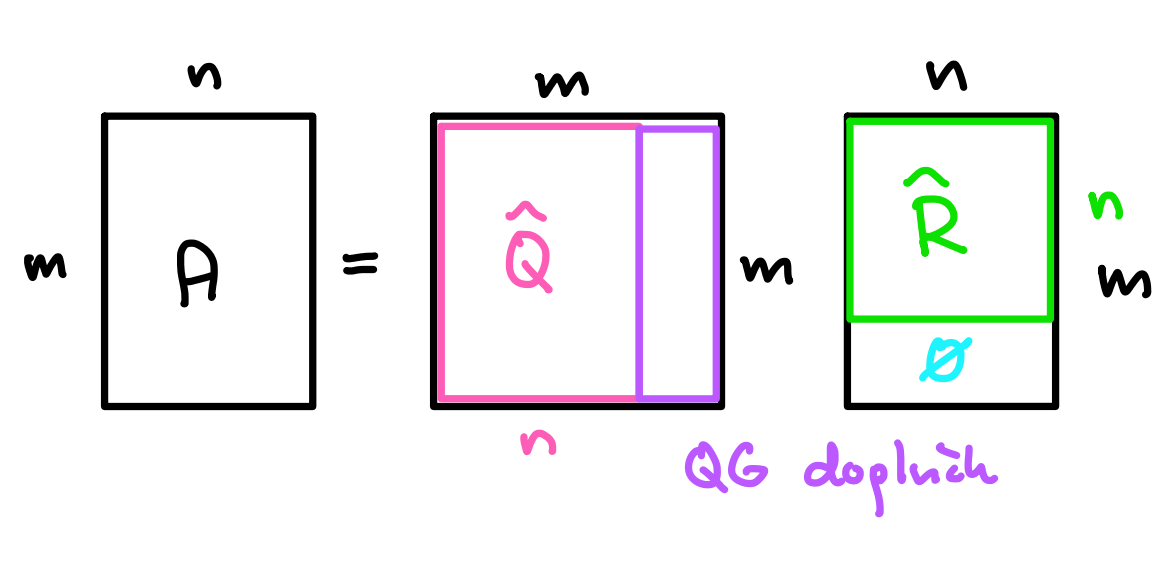

QG doplněk

→ řešení $QRx = b \Rightarrow Rx = Q^+ b$ + zpětná substituce

Gram-Schmidt

```
pro j = 1,...,n :
    q_j = a_j
    pro i = 1,...,j-1 :
        r_ij = q_i^+ a_j
        q_j = q_j - r_ij q_i
    r_jj = ||q_j||
    q_j = q_j / r_jj
```

Modifikovaný Gram-Schmidt

```
pro j = 1,...,n :
    q_j = a_j
pro j = 1,...,n :
    r_jj = ||q_j||
    q_j = q_j / r_jj
    pro i = j+1,...,n
        r_ji = q_j^+ q_i
        q_i = q_i - r_ji q_j
```

→ liší se jen přeuspořádáním

→ náročnost $\sim 2mn^2$ → $4m$ operací pro $n^2/2$

→ v GS může být problém, pokud při ortogonalizačním kroku je vektor blízko podprostoru předchozích vektorů

⇒ numerická chyba odčítání blízkých čísel

→ v MGS vždy počítáme projekce na již zortogonalizované vektory na předchozí

→ GS obecně nestabilní, MGS stabilnější výrazně

→ získávají neúplný QR rozklad

Householderova triangularizace

→ zisk úplného QR rozkladu pomocí Householderových zrcadlení

$$Q_n \cdots Q_1 A = R \,, \text{ kde } \qquad Q_k = \begin{array}{c} \begin{bmatrix} 1 & 0 \\ 0 & F \end{bmatrix} \begin{matrix} k-1 \\ m-k+1 \end{matrix} \\ \begin{matrix} k-1 & m-k+1 \end{matrix} \end{array},$$

kde F provádí zrcadlení

$$\begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \xrightarrow[F]{\text{zrcadlení}} \begin{bmatrix} \|x\| \\ \emptyset \end{bmatrix}$$

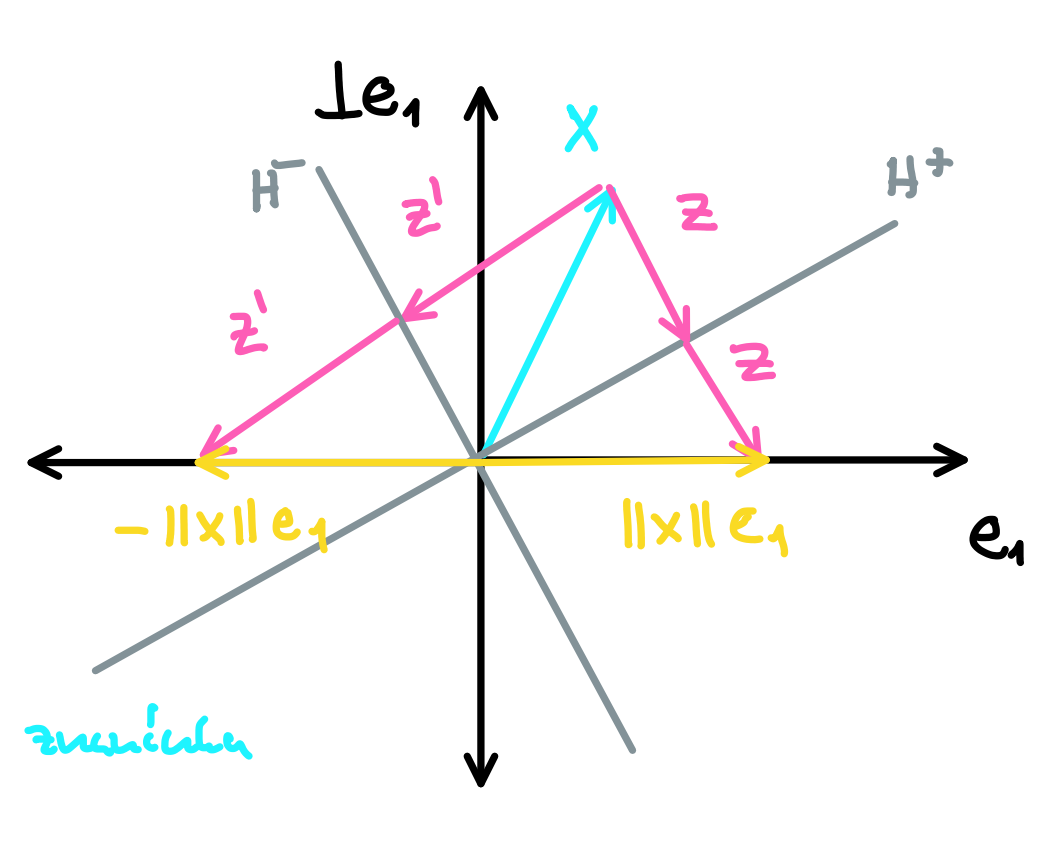

→ vektor roviny zrcadlení

$$V = -\operatorname{sgn}(x_1)\|x\| e_1 - x$$

tvar F nezávisí na volbě znaménka

$$F = 1 - 2\frac{vv^+}{\|v\|^2}$$

→ matice Q se často nekonstruuje, ale jde volbou $b = e_j$

→ náročnost $\sim 4\left(\frac{1}{2}mn^2 - \frac{1}{6}n^3\right)$

4 operace v projekci $1 - 2vv^+a$

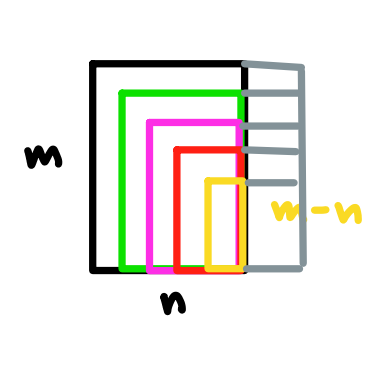

→ metoda je zpětně stabilní $\quad \|\delta A\| = \|A\| \, \mathcal{O}(\varepsilon_M)$, ale záleží na podmíněnosti úlohy

→ analogicky metoda Givensových rotací pomocí rotací

SVD rozklad

→ pro $A \in \mathbb{C}^{m \times n} \qquad A = U \Sigma V^+$, kde

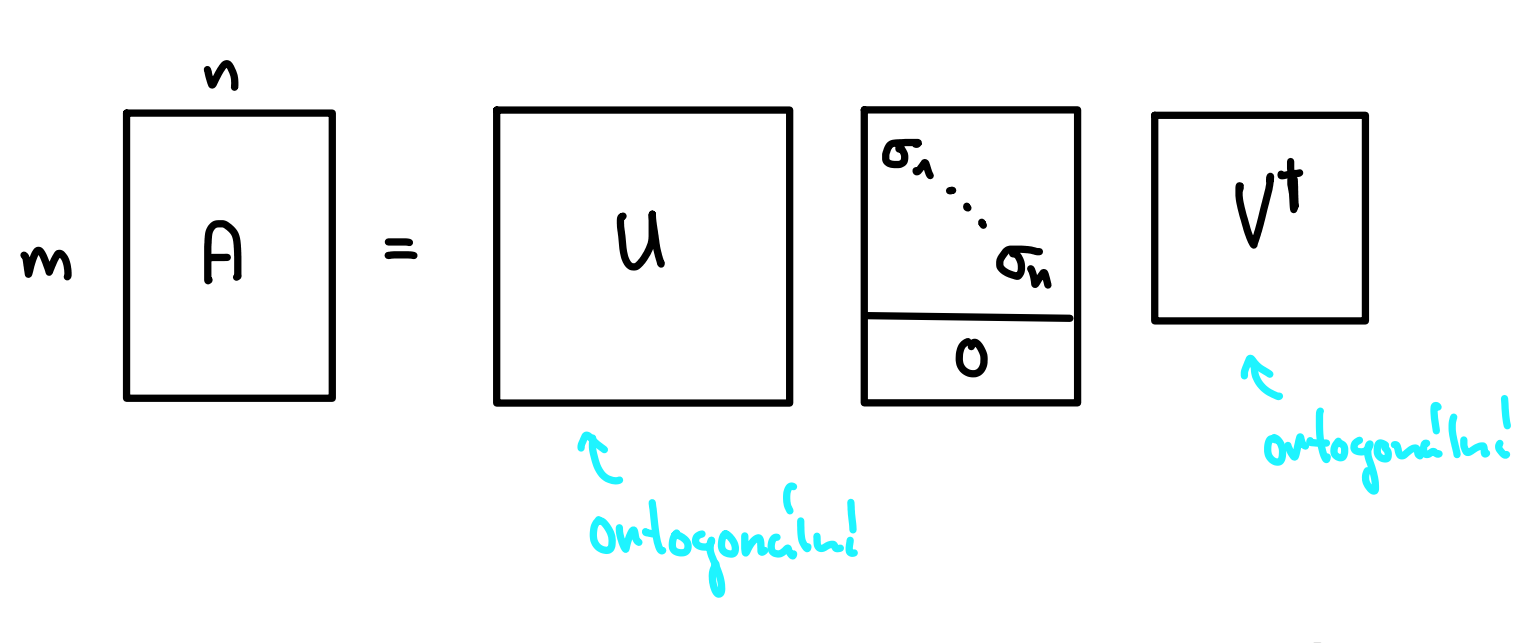

ortogonální — ortogonální

→ pointa: nalezení $\{u_i\}$ a $\{v_i\}$ takových, že $Av_i = \sigma_i u_i$

⇒ jak se jednotková sféra transformuje na sféroid s hlavními osami u_i

⇒ transformace pravoúhlé mřížky na pravoúhlou

→ low-rank aproximace ⇒ $A = \sum_j u_j \sigma_j v_j^+$

→ nutné řešit iterativně

Řešení přeurčených soustav

→ $Ax = b$ nemá řešení, ale hledáme řešení s nejmenším $\|Ax - b\|$

≡ metoda nejmenších čtverců

řešení přeurčení $\iff A^+ r = 0$, kde $r = b - Ax \iff A^+Ax = A^+b \iff Ax = \overset{\text{projektor na } \mathcal{R}(A)}{P}b$

(1) řešení normální rovnice

- řešíme $\underbrace{A^+A}_{\text{je pozitivně definitní}}x = A^+b \Rightarrow$ lze použít Choleského rozklad
- problém s podmíněností: pro $\kappa(A)$ má $\kappa(A^+A) = \kappa(A)^2$

(2) QR rozklad

- pro $A = \hat{Q}\hat{R}$ lze P napsat jako $A(A^+A)^{-1}A^+$
- $\hat{Q}$ nese stejnou informaci o $\mathcal{R}(A) \Rightarrow P = \hat{Q}\underbrace{(\hat{Q}^+\hat{Q})}_{1}{}^{-1}\hat{Q}^+ = \hat{Q}\hat{Q}^+$

  $\Rightarrow \hat{R}x = \hat{Q}^+b$
- je hodně stabilnější

(3) SVD rozklad

- $\mathcal{R}(A)$ je dáno $\hat{U} \Rightarrow P = \hat{U}\hat{U}^+$

  $\Rightarrow x = \hat{V}\hat{\Sigma}^{-1}\hat{U}^+b$
- nejstabilnější, vhodné pro téměř singulární matice A

Využití QR rozkladu při hledání vlastních čísel

- matice nemusí být diagonalizovatelná
- podobnostní transformace nemění vlastní čísla
- obecný Schurův rozklad $A = QTQ^+$

  T má vlastní čísla na diagonále, ◹ horní

  Q nemusí mít vlastní vektory, má jen pro normální matice $[A, A^+] = 0$
- pro $n > 4$ nutné iterativní metody

Mocninná iterace

```
zvol v^(0)
pro k = 1,...
    w = A v^(k-1)
    v^(k) = w / ||w||
    λ^(k) = v^k+ A v^k
```

- konverguje k největšímu vlastnímu číslu, jehož vlastní vektor je obsažen v $v^{(0)}$
- konvergence $|\lambda^{(k)} - \lambda_1| = \mathcal{O}\left(\left|\frac{\lambda_2}{\lambda_1}\right|^{2k}\right)$

  dvě největší vlastní čísla

Inverzní iterace

- matice $A - \mu\mathbb{1}$ má stejné vlastní vektory
- pokud je μ blízko λ_j, pak má matice $(A - \mu\mathbb{1})^{-1}$ největší vlastní číslo $1/(\lambda_j - \mu)$

  ⇒ najdeme pomocí mocninné iterace

```
zvol v^0 a μ blízké λ_j
pro k = 1,...
    vyřeš  (A - μ1) w = v^(k-1)
    v^(k) = w / ||w||
    λ^(k) = v^(k)+ A v^(k)
```

Rayleighova metoda

→ postupně updatujeme μ pomocí $\lambda^{(k)}$

```
zvol v^(0) a λ^(0) blízké λ_j
pro k = 1,...
    vyřeš  (A - λ^(k-1) 1) w = v^(k-1)
    v^(k) = w / ||w||
    λ^(k) = v^(k)+ A v^(k)
```

→ kubická konvergence

Metody pro všechny vlastní vektory

1) Redukce matice A na
   - a) Hessenbergův tvar ≡ horní ◹ + 1 dolní subdiagonála
   - b) tridiagonální tvar ← pro symetrické nebo hermitovské

- pomocí Householderových zrcadlení nebo Givensových rotací

2) Výpočet Schurova rozkladu

pro Hessenbergův tvar či tridiagonální tvar

→ základem je QR rozklad

```
A^(0) = A
pro k = 1,...
    najdi QR rozklad  A^(k-1) = Q^(k) · R^(k)
    A^(k) = R^(k) · Q^(k)
```

⇒ pak máme $A^{(k)} = Q^{+(k)} A^{(k-1)} Q^{(k)}$,

tj. podobnostní transformace.

→ pro urychlení se používají tzv. shifty