B8.1 Faktorizace matic a jejich využití v numerické LA

→ základní úlohy numerické lineární algebry
- $Ax = b$
- $Ax = \lambda x$
- $Ax = b$ pro přeurčený systém

LU rozklad

≡ rozklad matice $A = LU$, kde L je Δ a U je ∇ pomocí Gaussovy eliminace pro $A \in \mathbb{C}^{n \times n}$

→ lze rozepsat pomocí série dolních trojúhelníkových matic, které realizují řádkové úpravy
jejich součin je také Δ

$$A^{(1)} = L_1 A \text{, kde } L_1 = \begin{bmatrix} 1 & & & 0 \\ -l_{21} & 1 & & \\ \vdots & 0 & \ddots & \\ -l_{n1} & 0 & \cdots & 1 \end{bmatrix} \qquad l_{ij} = \frac{a_{ij}^{(k-1)}}{a_{jj}^{(k-1)}}$$
pro $i > j$

$$\Rightarrow \quad L_{n-1} \cdots L_1 A = U$$
$$A = L_1^{-1} \cdots L_{n-1}^{-1} U$$

Pivotizace

→ rozklad může být nestabilní pro a_{kk} blízko nule
⇒ pivotizace ≡ přeskupení řádků, aby na diagonále byl největší element

→ je možná i sloupcová, ale to zvyšuje náročnost metody na $\sim n^3$ oproti řádkové, která je $\sim n^2$

$$L_{n-1} P_{n-1} \cdots L_1 P_1 A = U \xrightarrow{\text{lze přepsat}} \underbrace{L'_{n-1} \cdots L'_1}_{\text{mají přeuspořádané prvky}} \underbrace{P_{n-1} \cdots P_1}_{\text{permutační matici lze uložit jako vektor}} A = U$$
matice prohození sloupců

Algoritmus s řádkovou pivotizací

náročnost :

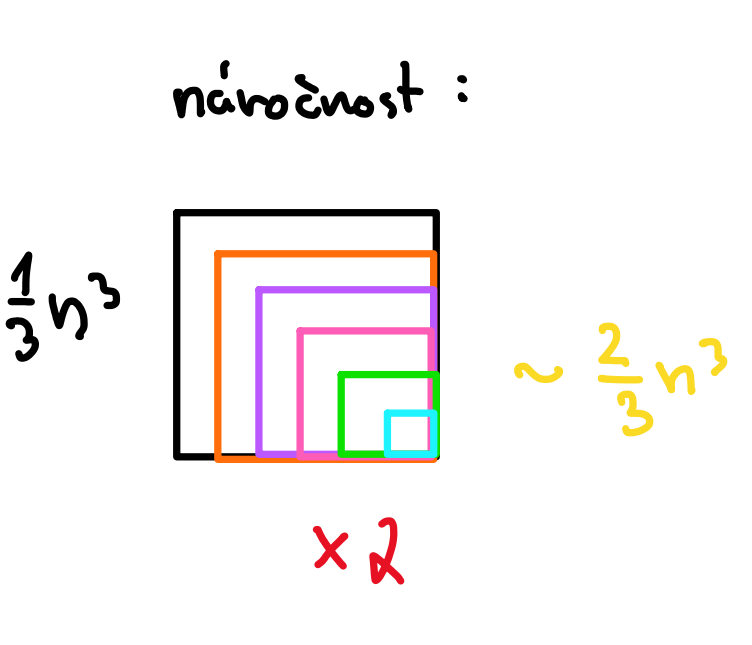

```
$U = A,\ L = I,\ P = I$
pro $k = 1, \dots, n-1$:
    najdi $j \geq k$  $\max |u_{jk}|$
    prohoď  $u_{k(k:n)} \leftrightarrow u_{j(k:n)}$
    prohoď  $l_{k(1:k-1)} \leftrightarrow l_{j(1:k-1)}$
    prohoď  $P_{k(1:n)} \leftrightarrow P_{j(1:n)}$
    pro $j = k+1, n$:
        $l_{jk} = u_{jk} / u_{kk}$
        $u_{j(k:n)} = u_{j(k:n)} - l_{jk} u_{k(k:n)}$
```
2 operace

$L_k = 1 - \vec{l}_k \vec{e}_k$
$L_k^{-1} = 1 + \vec{l}_k \vec{e}_k$

→ řešení soustavy: $Ax = b \iff PAx = Pb \qquad \overbrace{L^{-1}PA}^{U}x = L^{-1}Pb$
⇒ řešíme $Ly = Pb \wedge Ux = y$ → obě $\sim n^2$
⇒ vyplatí se pokud $A = \text{konst.}$ a b se mění

→ bez pivotizace není zpětně stabilní, s pivotizací ano
- bez pivotizace $\underbrace{\tilde{L}\tilde{U}}_{\text{spočtené}} = A + \delta A \qquad \|\delta A\| = \underbrace{\|\tilde{L}\| \|\tilde{U}\|}_{\text{mohou být obrovské}} \mathcal{O}(\varepsilon_M)$
- s pivotizací $\tilde{L}\tilde{U} = \tilde{P}A + \delta A \qquad \|\delta A\| = \|A\| \, \mathcal{O}(\rho_A \varepsilon_M)$

$$\rho_A = \frac{\max |\tilde{u}_{ij}|}{\max |a_{ij}|} \sim \sqrt{n} \leq 2^n$$
typicky — maximálně

Choleského rozklad

≡ speciální pro A symetrickou pozitivně definitní, pak lze psát
$$A = R^T R,$$
kde R je ∇ s kladnými prvky na diagonále

$$A = \begin{bmatrix} a_{11} & w^\dagger \\ w & K \end{bmatrix} = \begin{bmatrix} \alpha & 0 \\ \frac{w}{\alpha} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & K - \frac{ww^\dagger}{\alpha^2} \end{bmatrix} \begin{bmatrix} \alpha & \frac{w^\dagger}{\alpha} \\ 0 & 1 \end{bmatrix},$$
kde $\alpha = \sqrt{a_{11}}$

→ potřebujeme spočítat jen 1 matici ⇒ $\sim \frac{1}{3} n^3$

QR rozklad a SVD rozklad
a využití při řešení špatně podmíněných úloh a přeurčených soustav

QR rozklad

→ QR rozklad: $A = QR$, kde R je ∇ a Q je ortogonální pro $A^{m \times n}$

myšenka:
$$(\vec{a}_1 | \cdots | \vec{a}_n) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = x_1 \vec{a}_1 + \cdots x_n \vec{a}_n = \vec{y}$$

chceme přejít k ON bázi v $\vec{y}$ prostoru.
↳ pomocí Gram-Schmidtovy ortogonalizace
$$\left. \begin{aligned} a_1 &= r_{11} q_1 \\ a_2 &= r_{12} q_1 + r_{22} q_2 \\ &\vdots \end{aligned} \right\} \quad A = QR$$

→ úplný rozklad ≡ doplníme $\hat{Q}$ do plné matice $n \times n$ a $\hat{R}$ o nulové řádky

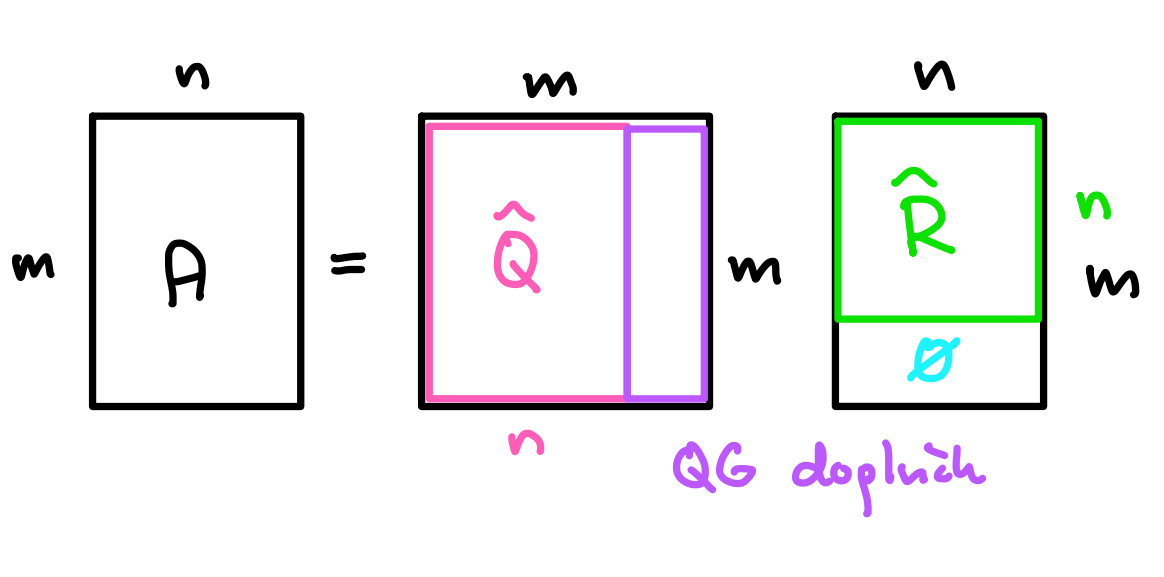

→ řešení $QRx = b \Rightarrow Rx = Q^\dagger b$ + zpětná substituce

Gram-Schmidt

```
pro $j = 1, \dots, n$:
    $q_j = a_j$
    pro $i = 1, \dots, j-1$:
        $r_{ij} = q_i^\dagger a_j$
        $q_j = q_j - r_{ij} q_i$
    $r_{jj} = \|q_j\|$
    $q_j = q_j / r_{jj}$
```

Modifikovaný Gram-Schmidt

```
pro $j = 1, \dots, n$:
    $q_j = a_j$
pro $j = 1, \dots, n$:
    $r_{jj} = \|q_j\|$
    $q_j = q_j / r_{jj}$
    pro $i = j+1, \dots, n$
        $r_{ji} = q_j^\dagger q_i$
        $q_i = q_i - r_{ji} q_j$
```

→ liší se jen přeuspořádáním

→ náročnost $\sim 2mn^2$ → $4m$ operací pro $n^2/2$

→ v GS může být problém, pokud při ortogonalizačním kroku je vektor blízko podprostoru předchozích vektorů
⇒ numerická chyba odčítání blízkých čísel

→ v MGS vždy počítáme projekce na již zortogonalizované vektory na předchozí

→ GS obecně nestabilní, MGS stabilnější výrazně

→ získávají neúplný QR rozklad

Householderova triangularizace

→ zisk úplného QR rozkladu pomocí Householderových zrcadlení
$$Q_n \cdots Q_1 A = R, \text{ kde } \quad Q_k = \begin{array}{cc|c} 1 & 0 & k-1 \\ 0 & F & m-k+1 \\ \hline k-1 & m-k+1 & \end{array},$$

kde F provádí zrcadlení
$$\begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \xrightarrow[F]{\text{zrcadlení}} \begin{bmatrix} \|x\| \\ \emptyset \end{bmatrix}$$

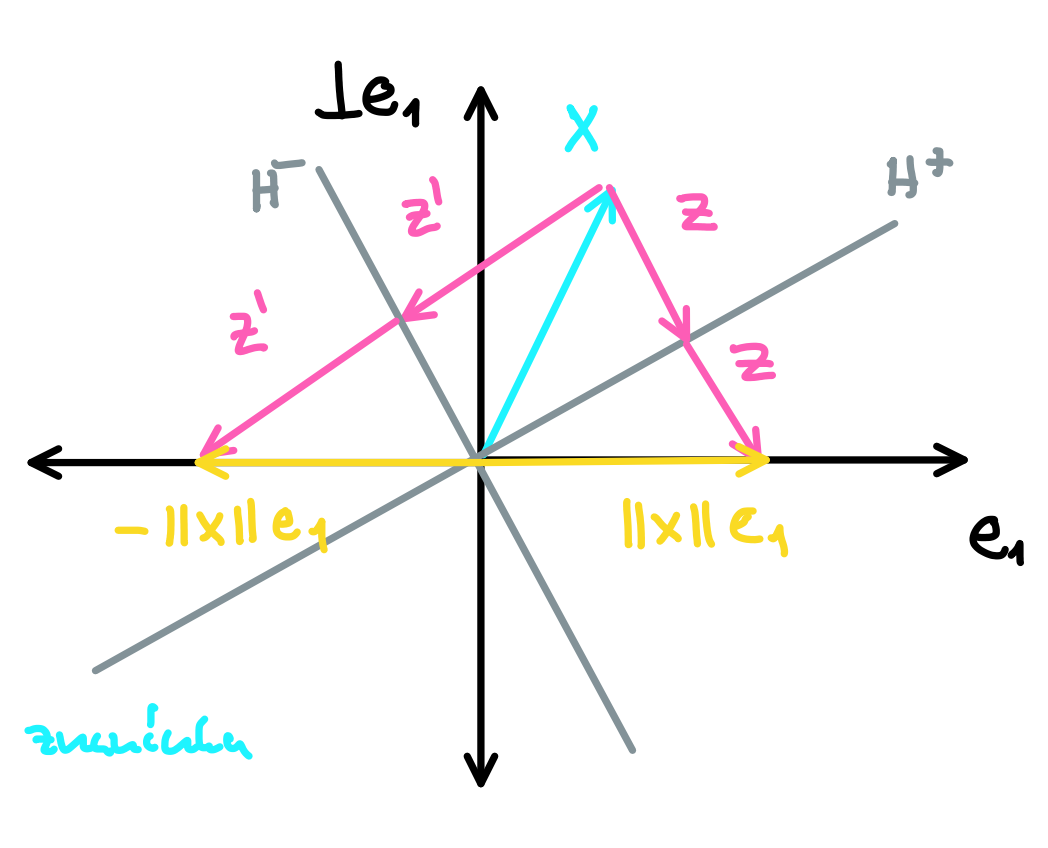

→ vektor roviny zrcadlení
$$v = -\text{sgn}(x_1) \|x\| e_1 - x$$
tvar F nezávisí na volbě znaménka

$$F = 1 - 2 \frac{vv^\dagger}{\|v\|^2}$$

→ matice Q se často nekonstruuje, ale jde volbou $b = e_j$

→ náročnost $\sim 4 \left(\frac{1}{2} mn^2 - \frac{1}{6} n^3 \right)$
4 operace v projekci $1 - 2vv^\dagger a$

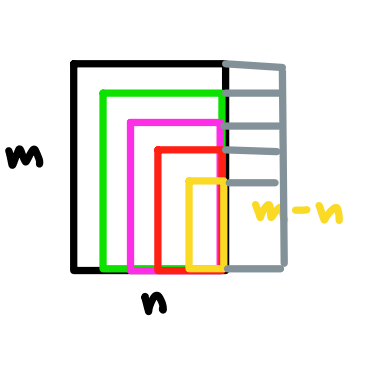

→ metoda je zpětně stabilní $\quad \|\delta A\| = \|A\| \, \mathcal{O}(\varepsilon_M)$, ale záleží na podmíněnosti úlohy

→ analogicky metoda Givensových rotací pomocí rotací

SVD rozklad

→ pro $A \in \mathbb{C}^{m \times n}$ $\quad A = U \Sigma V^\dagger$, kde

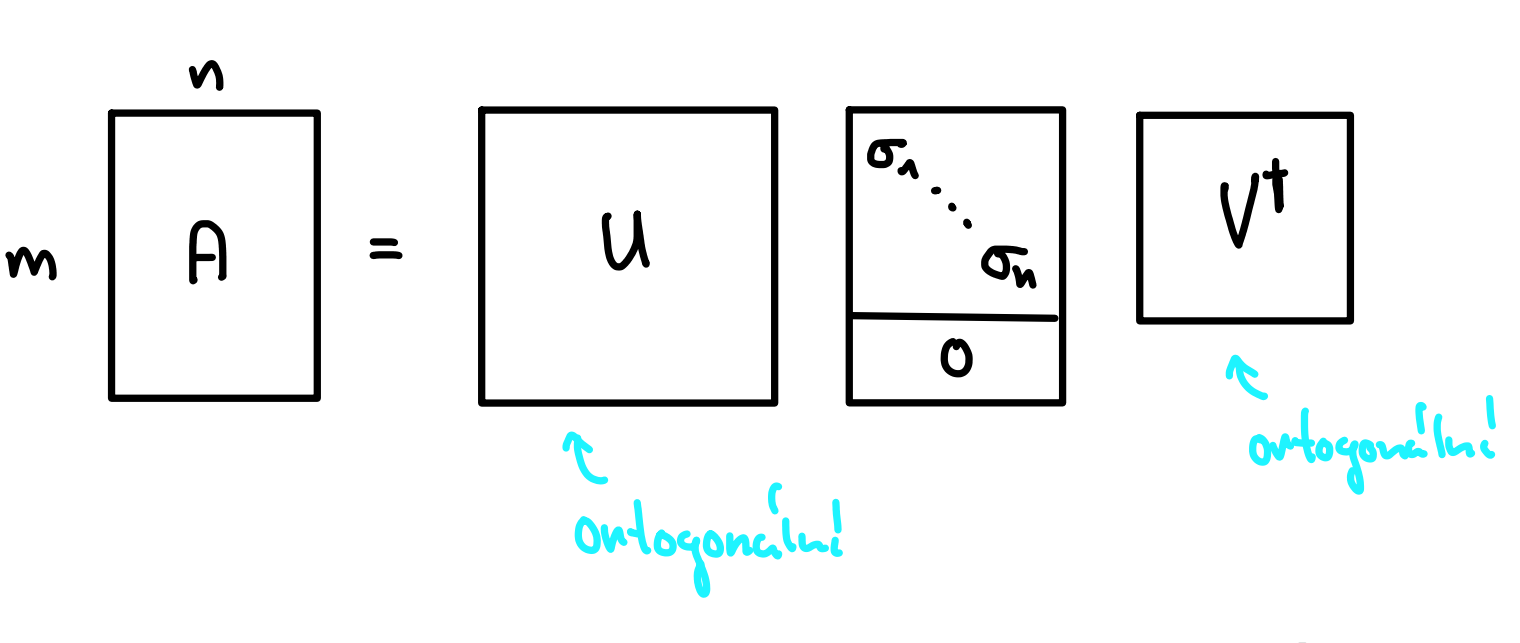

→ pointa: nalezení $\{u_i\}$ a $\{v_i\}$ takových, že $Av_i = \sigma_i u_i$
⇒ jak se jednotková sféra transformuje na elipsoid s hlavními osami u_i
⇒ transformace pravoúhlé mřížky na pravoúhlou

→ low-rank aproximace ⇒ $A = \sum_j u_j \sigma_j v_j^\dagger$

→ nutné řešit iterativně

Řešení přeurčených soustav

→ $Ax = b$ nemá řešení, ale hledáme řešení s nejmenším $\|Ax - b\|$
≡ metoda nejmenších čtverců

řešení přeurčené $\iff A^\dagger r = 0$, kde $r = b - Ax \iff A^\dagger Ax = A^\dagger b \iff Ax = \overset{\text{projektor na } \mathcal{R}(A)}{P} b$

(1) řešení normální rovnice
- řešíme $\underbrace{A^\dagger A}_{\text{je pozitivně definitní}} x = A^\dagger b$ ⇒ lze použít Choleského rozklad
- problém s podmíněností: pro $\kappa(A)$ má $\kappa(A^\dagger A) = \kappa(A)^2$

(2) QR rozklad
- pro $A = \hat{Q}\hat{R}$ lze P napsat jako $A(A^\dagger A)^{-1} A^\dagger$
- $\hat{Q}$ nese stejnou informaci o $\mathcal{R}(A)$ ⇒ $P = \hat{Q} (\underbrace{\hat{Q}^\dagger \hat{Q}}_{1_{n \times n}})^{-1} \hat{Q}^\dagger = \hat{Q}\hat{Q}^\dagger$
⇒ $\hat{R}x = \hat{Q}^\dagger b$
- je mnohem stabilnější

(3) SVD rozklad
- $\mathcal{R}(A)$ je dána $\hat{U}$ ⇒ $P = \hat{U}\hat{U}^\dagger$
⇒ $x = \hat{V} \hat{\Sigma}^{-1} \hat{U}^\dagger b$
- nejstabilnější, vhodná pro téměř singulární matice A

Využití QR rozkladu při hledání vlastních čísel

- matice nemusí být diagonalizovatelná
- podobnostní transformace nemění vlastní čísla
- obecný Schurův rozklad $A = QTQ^\dagger$
  T má vlastní čísla na diagonále, Δ horní
  Q nemusí mít vlastní vektory, má jen pro normální matice $[A, A^\dagger] = 0$
- pro $n > 4$ nutné iterativní metody

Mocninná iterace

```
zvol $v^{(0)}$
pro $k = 1, \dots$
    $w = A v^{(k-1)}$
    $v^{(k)} = w / \|w\|$
    $\lambda^{(k)} = v^{k\dagger} A v^k$
```

- konverguje k největšímu vlastnímu číslu, jehož vlastní vektor je obsažen v $v^{(0)}$
- konvergence
$$|\lambda^{(k)} - \lambda_1| = \mathcal{O}\left(\left| \underbrace{\frac{\lambda_2}{\lambda_1}}_{\text{dvě největší vlastní čísla}} \right|^{2k} \right)$$

Inverzní iterace

- matice $A - \mu \mathbb{1}$ má stejné vlastní vektory
- pokud je μ blízko λ_j, pak má matice $(A - \mu \mathbb{1})^{-1}$ největší vlastní číslo $1/(\lambda_j - \mu)$
⇒ najdeme pomocí mocninné iterace

```
zvol $v^0$ a $\mu$ blízké $\lambda_j$
pro $k = 1, \dots$
    vyřeš  $(A - \mu \mathbb{1}) w = v^{(k-1)}$
    $v^{(k)} = w / \|w\|$
    $\lambda^{(k)} = v^{(k)\dagger} A v^{(k)}$
```

Rayleighova metoda

→ postupně updatujeme μ pomocí $\lambda^{(k)}$

```
zvol $v^{(0)}$ a $\lambda^{(0)}$ blízké $\lambda_j$
pro $k = 1, \dots$
    vyřeš  $(A - \lambda^{(k-1)} \mathbb{1}) w = v^{(k-1)}$
    $v^{(k)} = w / \|w\|$
    $\lambda^{(k)} = v^{(k)\dagger} A v^{(k)}$
```

→ kubická konvergence

Metody pro všechny vlastní vektory

1) Redukce matice A na
   a) Hessenbergův tvar ≡ horní Δ + 1 dolní subdiagonála
   b) tridiagonální tvar ← pro symetrické nebo hermitovské
- pomocí Householderových zrcadlení nebo Givensových rotací

2) Výpočet Schurova rozkladu
pro Hessenbergův tvar či tridiagonální tvar
→ základem je QR rozklad

```
$A^{(0)} = A$
pro $k = 1, \dots$
    najdi QR rozklad  $A^{(k-1)} = Q^{(k)} \cdot R^{(k)}$
    $A^{(k)} = R^{(k)} \cdot Q^{(k)}$
```

⇒ pak máme $A^{(k)} = Q^{\dagger(k)} A^{(k-1)} Q^{(k)}$,
tj. podobnostní transformace.

→ pro urychlení se používají tzv. shifty