B8.7 Základy metody Monte Carlo

Centrální limitní věta

→ náhodná veličina X s $\langle X\rangle = a$ $\langle \Delta X^2\rangle = b^2$

→ uvažujeme aditivní proměnnou na systému:

$$A(x) = \sum_j X_j$$

↑ identické pozorovatelné $X_j \equiv X$

→ statistika pozorovatelné A:

$$\langle A\rangle = \left\langle \sum_j X_j \right\rangle \underset{\text{nezávislost}}{=} \sum_j \langle X_j\rangle \underset{\text{identické}}{=} N\langle X\rangle = Na$$

- korelace

$$\langle X_j X_k\rangle \underset{\text{nezávislost}}{=} \begin{cases} \langle X_j^2\rangle & j=k \\ \langle X_j\rangle\langle X_k\rangle & j\neq k \end{cases}$$

- rozptyl

$$\langle (\Delta A)^2\rangle = \left\langle \sum_{ij} \underset{\uparrow}{\Delta X_i \Delta X_j} \right\rangle = \sum_j \langle \Delta X_j^2\rangle = N\langle \Delta X\rangle = Nb^2$$

$$\Rightarrow \quad \sigma_N \propto \sqrt{N}$$

protože $\langle \Delta X_i \Delta X_j\rangle = \langle X_i X_j\rangle - \langle X_i\rangle\langle X_j\rangle$

Zákon velkých čísel

→ zajímáme se o průměr ↔ intenzivní veličinu, hustotu

$$\bar{A} := \frac{A}{N}$$

- střední hodnota: $\langle \bar{A} \rangle = \frac{1}{N}\langle A \rangle = \langle X \rangle = a$
- rozptyl: $\langle (\Delta \bar{A})^2 \rangle = \frac{1}{N^2} \langle (\Delta A)^2 \rangle = \frac{b^2}{N} \xrightarrow[N\to\infty]{} 0$

Centrální limitní věta

→ chování distribuce pro velká N

↳ $\sigma \propto \sqrt{N}$

⇒ zkoumáme chování okolo střední hodnoty přeškálování tak, aby rozdělení pro různá N měla stejný rozptyl

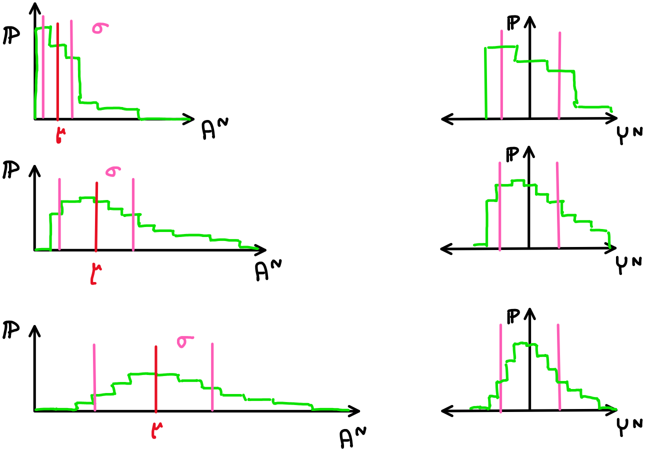

→ $$Y := \frac{A - N\langle X \rangle}{\sqrt{N}}$$

→ pro charakteristickou funkci máme:

$$\phi_Y(t) = \langle e^{itY}\rangle = \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j (\underbrace{X_j - \langle X\rangle}_{\Delta A_j})}\right\rangle$$

$$= \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j \Delta X_j}\right\rangle \underset{\text{nezávislost}}{=} \left\langle e^{i\frac{t}{\sqrt{N}}\Delta X}\right\rangle^N$$

$$= \left[1 - \frac{1}{2}\frac{t^2}{N}\langle\Delta X^2\rangle + \mathcal{O}\left(\frac{1}{N^{3/2}}\right)\right]^N$$

$$\xrightarrow{N\to\infty} e^{-\frac{t^2}{2}\underbrace{\langle\Delta X^2\rangle}_{b^2}} \leftarrow$$

charakteristická funkce normálního rozdělení s $\mu = 0$

↳ nenulový pouze druhý kumulant

→ Centrální limitní věta:

$$Y^{(N)} \xrightarrow[N\to\infty]{} \text{normální rozdělení}$$

$$\rho(y) = \frac{1}{\sqrt{2\pi b^2}} e^{-\frac{y^2}{2b^2}}$$

$$\Rightarrow \quad A \approx N\langle X\rangle + \sqrt{N}\,\mathcal{N}(0, b^2)$$

Odhad chyby MC

⇒ průměr N nezávislých náhodných veličin dá rozdělení:

$$\bar{A} = \frac{1}{N}\sum_j X_j \Rightarrow \langle\bar{A}\rangle = \langle X\rangle = a$$

$$\langle\Delta\bar{A}^2\rangle = \frac{1}{N}\langle\Delta X^2\rangle = \frac{b^2}{N}$$

a tedy směrodatná odchylka $\sigma(A_N) = \frac{b}{\sqrt{N}}$

→ $\mathbb{P}(|\bar{A}_N - a| \le 3\sigma) \approx 0.9973$

↑ $\sim \frac{1}{\sqrt{N}}$

→ pravděpodobnostná chyba: $r \approx 0.67\sigma = 0.67 \frac{b}{\sqrt{N}}$

↳ náhodná veličina je s pravděpodobností 1/2 v intervalu $|\bar{A}_N - a| \leq r$

→ není to horní odhad chyby, ale pravděpodobná chyba

⇒ chyba může být větší, ale pravděpodobnost toho je malá

Integrace metodou MC

Metoda prostého vzorkování

náhodná proměnná na [a,b]
s rovnoměrným rozdělením

$$I = \int_a^b dx\, f \approx \underbrace{\frac{b-a}{N}}_{\text{míra na } [a,b]} \sum_j^N f(x_j)$$

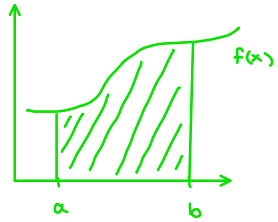

→ nahlížíme na integrál jako na průměrování funkce přes interval

→ v d-dim. prostoru

$$I = \int_\Omega d^d x\, f(x_1, \dots, x_d) \approx \frac{|\Omega|}{N} \sum_j^N f(x_1^j, \dots, x_d^j)$$

→ odhad chyby: $r \approx 0.67\, \sigma_I \approx 0.67 \frac{b-a}{\sqrt{N}} \sigma_f$,

kde varianci funkce f lze odhadnout za běhu:

$$\sigma_f^2 = \langle f^2 \rangle - \langle f \rangle^2 \approx \frac{1}{N} \sum_j^N f^2(x_j) - \left[\frac{1}{N} \sum_j^N f(x_j) \right]^2$$

Metoda preferenčního vzorkování

→ chyba závisela na σ_f ⇒ pokud je f téměř konstantní, pak malá, naopak pokud σ_f velké ⇒ velká chyba

→ snížení σ_f pomocí vhodné váhové funkce

$$w(x) \quad : \quad w(x) > 0 \quad \wedge \quad \int_a^b dx\, w = 1,$$

která je "podobná" f ⇔ $\frac{f}{w} \approx$ konst.

$$I = \int_a^b dx\, f = \int_a^b dx\, \frac{f}{w}\, w = \int_0^1 dy\, g(y) \approx \frac{1}{N} \sum_j^N g(\underset{\uparrow}{y_j}),$$

kde $$y(x) = \int_a^x dt\, w(t)$$

$$dy = w\, dx \qquad g(y) = \frac{f(x(y))}{w(x(y))}$$

y_j → náhodná veličina s rovnoměrným rozdělením na $[0,1]$

⇒ musím umět invertovat CDF $x = x(y)$

→ pokud neumím invertovat CDF, můžu použít:

$$I \approx \frac{1}{N} \sum_j \frac{f(x_j)}{w(x_j)} \leftarrow$$ x_j náhodná proměnná s rozdělením $w(x)$ na $[a,b]$

Přesnost integračních metod

→ metoda řádu $O(1/n^k)$ v d-dimenzích, celkem bodů $N = n^d$

⇒ přesnost $O(N^{-k/d})$

→ MC metoda: $O(N^{-1/2})$

$\Rightarrow$ srovnatelní pro $d = 2k$

Generování pseudonáhodných čísel s daným rozdělením

→ máme uniformní náhodnou proměnnou na $[0,1]$ a chceme generovat čísla s jiným rozdělením

Inverze distribuční funkce

→ chci generovat x s rozdělením $\rho(x)$

$$F(x) \equiv \mathbb{P}(X < x) = \int_{-\infty}^{x} dt\, \rho(t),$$

pak jednoduše: $x_i = F^{-1}(\xi_i)$, kde ξ_i je uniformní

př.: exp rozdělení

$$\rho(x) = \lambda e^{-\lambda x} \Rightarrow F(x) = \int_0^x \lambda e^{-\lambda t}\, dt = 1 - e^{-\lambda x}$$

$$\Rightarrow x = F^{-1}(\xi_i) = -\frac{1}{\lambda} \ln \xi_i$$

trik $1 - \xi_i = \xi_i'$

př. rozdělení na sféře

$$dS = r^2 \sin\vartheta\, dr\, d\vartheta\, d\varphi \Rightarrow \rho(\vartheta, \varphi) = \frac{\sin\vartheta}{4\pi}$$ ✓ normalizace

$$F(\vartheta, \varphi) = \frac{\varphi}{2\pi} \frac{1 - \cos\vartheta}{2}$$

$$\Rightarrow (\vartheta_i, \varphi_i) = \left(\arccos(1 - 2\xi_i),\ 2\pi \chi_i \right)$$

př.: normální rozdělení

→ Erf nelze invertovat, trik ve 2D

$$x_i = r_i \cos\varphi_i \qquad r_i = \sqrt{-2\ln\xi_i}$$

$$y_i = r_i \sin\varphi_i \qquad \varphi_i = 2\pi\chi_i$$

Von Neumannova metoda

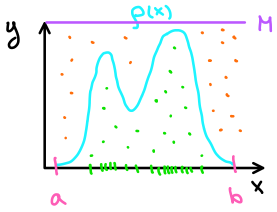

```
vygeneruj $\xi_i, \eta_i \in [0,1]$
$x_i = a + (b-a)\xi_i$
$y_i = M\eta_i$
pokud $y_i \le \rho(x_i)$
    přijmi
jinak
    cycle
```

Metropolis-Hastingsův algoritmus

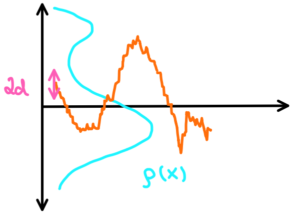

```
r = random()
xtrial = x + d(2r - 1)
ratio = ρ(xtrial) / ρ(x)
if radio ≥ 1 or ratio ≥ random()
    x = xtrial
return x
```

→ funguje i ve více dimenzích

→ má vyšší korelaci

→ proč funguje v limitě dlouhé procházky?

$N_n(x)$ … hustota nezávislých chodců, kteří vyrazili náhodně po n krocích

$$\Delta N_n(x) = N_n(y)P(y\to x) - N_n(x)P(x\to y)$$

v ustáleném stavu

$$= N_n(y)\, P(x\to y) \left[\frac{P(y\to x)}{P(x\to y)} - \frac{N_n(x)}{N_y(x)}\right] \approx 0$$

$$\frac{P(y\to x)}{P(x\to y)} = \frac{\cancel{T(y\to x)}\, A(y\to x)}{\cancel{T(x\to y)}\, A(x\to y)} = \frac{\rho(x)}{\rho(y)}$$

pravděpodobnosti vykrácení

$$A(x\to y) = \begin{cases} 1 & \rho(x) \geq \rho(y) \\ \frac{\rho(y)}{\rho(x)} & \text{jinak} \end{cases} \qquad A(y\to x) = \begin{cases} \frac{\rho(x)}{\rho(y)} & \rho(x) \geq \rho(y) \\ 1 & \text{jinak} \end{cases}$$

Aplikace metod MC

Termodynamické MC

→ výpočet středních hodnot TD veličin systému pomocí MC

- založeno na ergodické hypotéze ≡ průměrování přes fázový prostor

$$\langle X \rangle = \int d^{3N}p\, d^{3N}q \; X(p,q) \; \underbrace{\rho(p,q)}_{\text{hustota pravděpodobnosti ve fázovém prostoru}}$$

→ nejčastěji používáme pro kanonický systém:

$$\rho(q,p\,;N,V,T) = \frac{1}{Z_c} e^{-\beta H(p,q)}$$

- pokud máme systém identických částic a Hamiltonián je ve tvaru

$$H(p,q) = K(p) + V(q),$$

pak lze vyintegrovat přes hybnosti

$$\langle X \rangle = \frac{1}{Q_{NVT}} \int d^{3N}q \, X(q)\, e^{-\beta V(q)} ,$$

kde $$Q_{NVT} = \int d^{3N} e^{-\beta V(q)}$$

→ v MC aproximujeme

$$\langle X \rangle \approx \frac{1}{N_{MC}} \sum_{j=1}^{N_{MC}} X(\overset{\text{konfigurace}}{\sigma_j})$$

σ_i jsou náhodné konfigurace s $\rho(\sigma_i) \propto e^{-\beta H(\sigma_j)}$

→ výhodné je použít Metropolisův algoritmus

- preferenčně vybírá ty konfigurace, které nejvíce přispívají do střední hodnoty
- není potřeba znát normalizační partiční sumou, používáme jen podíl

$$\frac{\rho(\sigma_{trial})}{\rho(\sigma_k)} = \frac{\frac{1}{Z} e^{-\beta H(\sigma_{trial})}}{\frac{1}{Z} e^{-\beta(\sigma_k)}} = e^{-\beta \Delta E}$$

→ pokud $\Delta E > 0$ ⇒ číslo v int. $(0,1)$ ⇒ $e^{-\beta \Delta E} \overset{?}{>}$ random

→ pokud $\Delta E \leq 0$ ⇒ bereme 1 ⇒ akceptujeme

Simulace TD systému pomocí MC

1) inicializace ≡ vygenerujeme náhodnou počáteční konfiguraci s "rozumnou" E

2) termalizace ≡ několik kroků M-H algoritmu, abychom se dostali do rozumné oblasti

3) měření ≡ generujeme M-H kroky a určujeme veličiny in question, můžeme měřit až např. po 10 krocích, nebo provádíme sweepy

4) průměrování ≡ zprůměrování hodnot z kroků + průměrování z různých počátečních konfigurací

Geometrické MC – perkolace

- → studium počtu klastrů a jejich vlastností v "náhodných" strukturách
- → modelujeme reálný systém na specifické mřížce v d-dimenzionálním prostoru
- → mřížky můžeme obsazovat
  - pozice (site percolation)
  - vazby (bond percolation)

- → počet obsazených míst závisí na stavovém parametru – obsazovací pravděpodobnosti p – a je náhodný
  - obvykle se uvažuje nezávislá pro jednotlivá místa

Práh perkolace p_c ≡ obsazovací pravděpodobnost, při které se objeví spanning cluster

- pro nekonečnou mřížku je vždy pro $p > p_c$, ale nikdy pro $p < p_c$

- více sousedů => snazší propojit => nižší p_c

Hoshen-Kopelmanův algoritmus

- umožňuje najít všechny clustery na jeden průchod

1) systematicky projdi všechny body mřížky

2) přiřaď obsazenému místo číslo klasteru
   a) číslo klasteru obsazeného souseda
   b) nové číslo

3) vyřeš konflikty, pokud dva sousední body připadají různým clusterům
   → využijeme pomocné pole
   - přiřazujeme menší číslo při konfliktu
   - je nutné měnit všechna čísla při přečíslování

Geometrické MC – difúzí limitovaná agregace

→ generování komplexních struktur pomocí jednoduchých pravidel

→ růst systému je modelován posloupností náhodných stavů

→ pro porovnání modelu s realitou je potřeba určit veličiny zachycující charakter komplexní struktury

např.: fraktální dimenze $D_f \simeq \dfrac{\log N(a)}{\log L(a)}$

- $N(a)$ = počet částic ve čtverci (krychli) o straně a
- $L(a)$ = počet míst mřížky, která tvoří tuto stranu

Základní algoritmus DLA

1) inicializace → nastavení "semínek" → obsazení jednoho nebo více míst

2) opakuj následující kroky, dokud není struktura dostatečně velká

a) vypuštění nové částice např. na kružnici o poloměru $R_{start} > R_{max}$, kde R_{max} je aktuální max. vzdálenost agregované struktury

→ R_{start} v průběhu měnit, např. $R_{start} = R_{max} + 1$

b) difúzní pohyb ≡ náhodná procházka po mřížce, dokud není sousední místo obsazené, nebo $R > R_{kill}$

- pro větší efektivitu lze náhodně procházet jen pro $R < R_{jump}$, pro $R > R_{jump}$ provádíme skoky náhodně po kružnicích s $r = R - R_{start}$

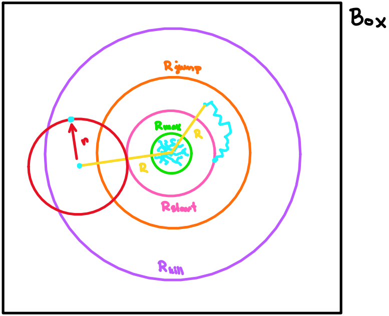c) agregace ≡ pokud je sousední místo obsazené, tak se částice agreguje