B8.7 Monte Carlo

neděle 24. května 2026 11:09

B8.7 Základy metody Monte Carlo

Centrální limitní věta

→ náhodná veličina X s $\langle X\rangle = a$ $\langle \Delta X^2\rangle = b^2$

→ uvažujeme aditivní proměnnou na systému:

$$A(x) = \sum_j X_j$$

↑ identické pozorovatelné $X_j \equiv X$

→ statistika pozorovatelné A :

$$\langle A\rangle = \Big\langle \sum_j X_j\Big\rangle \underset{\text{nezávislost}}{=} \sum_j \langle X_j\rangle \underset{\text{identické}}{=} N\langle X\rangle = Na$$

- korelace

$$\langle X_j X_k\rangle \underset{\text{nezávislost}}{=} \begin{cases} \langle X_j^2\rangle & j=k \\ \langle X_j\rangle\langle X_k\rangle & j\neq k \end{cases}$$

- rozptyl

$$\langle (\Delta A)^2\rangle = \Big\langle \sum_{ij} \underset{\uparrow}{\Delta X_i \Delta X_j}\Big\rangle = \sum_j \langle \Delta X_j^2\rangle = N\langle \Delta X\rangle = Nb^2$$

$$\Rightarrow \quad \sigma_N \propto \sqrt{N}$$

protože $\langle \Delta X_i \Delta X_j\rangle = \langle X_i X_j\rangle - \langle X_i\rangle\langle X_j\rangle$

Zákon velkých čísel

→ zajímáme se o průměr ↔ intenzivní veličinu, hustotu

$$\bar{A} := \frac{A}{N}$$

- střední hodnota: $\langle \bar{A} \rangle = \frac{1}{N}\langle A \rangle = \langle X \rangle = a$
- rozptyl: $\langle (\Delta \bar{A})^2 \rangle = \frac{1}{N^2} \langle (\Delta A)^2 \rangle = \frac{b^2}{N} \xrightarrow[N\to\infty]{} 0$

Centrální limitní věta

→ chování distribuce pro velká N

↳ $\sigma \propto \sqrt{N}$

⇒ zkoumáme chování okolo střední hodnoty přeškálovaní tak, aby rozdělení pro různá N měla stejný rozptyl

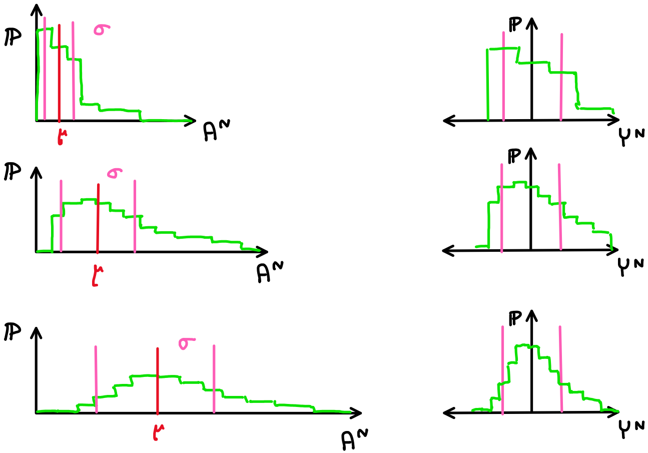

→ $$Y := \frac{A - N\langle X \rangle}{\sqrt{N}}$$

→ pro charakteristickou funkci máme:

$$\phi_Y(t) = \langle e^{itY}\rangle = \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j (\underbrace{X_j - \langle X\rangle}_{\Delta A_j})}\right\rangle$$

$$= \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j \Delta X_j}\right\rangle \underset{\text{nezávislost}}{=} \left\langle e^{i\frac{t}{\sqrt{N}}\Delta X}\right\rangle^N$$

$$= \left[1 - \frac{1}{2}\frac{t^2}{N}\langle \Delta X^2\rangle + \mathcal{O}\left(\frac{1}{N^{3/2}}\right)\right]^N$$

$$\xrightarrow{N\to\infty} e^{-\frac{t^2}{2}\underbrace{\langle \Delta X^2\rangle}_{b^2}} \leftarrow$$

charakteristická funkce normálního rozdělení s $\mu = 0$

↳ nenulový pouze druhý kumulant

→ Centrální limitní věta:

$$Y^{(N)} \xrightarrow[N\to\infty]{} \text{normální rozdělení}$$

$$\rho(y) = \frac{1}{\sqrt{2\pi b^2}} e^{-\frac{y^2}{2b^2}}$$

$$\Rightarrow \quad A \approx N\langle X\rangle + \sqrt{N}\,\mathcal{N}(0, b^2)$$

Odhad chyby MC

⇒ průměr N nezávislých náhodných veličin dá rozdělení:

$$\bar{A} = \frac{1}{N}\sum_j X_j \Rightarrow \langle \bar{A}\rangle = \langle X\rangle = a$$

$$\langle \Delta \bar{A}^2\rangle = \frac{1}{N}\langle \Delta X^2\rangle = \frac{b^2}{N}$$

a tedy směrodatná odchylka $\sigma(A_N) = \frac{b}{\sqrt{N}}$

→ $\mathbb{P}(|\bar{A}_N - a| \le 3\sigma) \approx 0.9973$

$\uparrow \sim \frac{1}{\sqrt{N}}$

→ pravděpodobnostná chyba: $r \approx 0.67\sigma = 0.67 \frac{b}{\sqrt{N}}$

↳ náhodná veličina je s pravděpodobností 1/2 v intervalu $|\bar{A}_N - a| \leq r$

→ není to horní odhad chyby, ale pravděpodobná chyba

⇒ chyba může být větší, ale pravděpodobnost toho je malá

Integrace metodou MC

Metoda prostého vzorkování

náhodná proměnná na [a,b]
s rovnoměrným rozdělením

$$I = \int_a^b dx\, f \approx \underbrace{\frac{b-a}{N}}_{\text{míra na } [a,b]} \sum_j^N f(x_j)$$

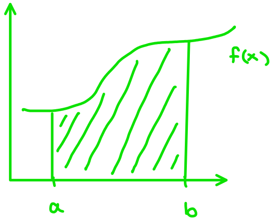

→ nahlížíme na integrál jako na průměrování funkce přes interval

→ v d-dim. prostoru

$$I = \int_\Omega d^d x\, f(x_1,\dots,x_d) \approx \frac{|\Omega|}{N} \sum_j^N f(x_1^j,\dots,x_d^j)$$

→ odhad chyby: $r \approx 0.67\,\sigma_I \approx 0.67 \frac{b-a}{\sqrt{N}} \sigma_f$,

kde varianci funkce f lze odhadnout za běhu:

$$\sigma_f^2 = \langle f^2 \rangle - \langle f \rangle^2 \approx \frac{1}{N} \sum_j^N f^2(x_j) - \left[\frac{1}{N} \sum_j^N f(x_j)\right]^2$$

Metoda preferenčního vzorkování

→ chyba závisela na σ_f ⇒ pokud je f téměř konstantní, pak malá, naopak pokud σ_f velké ⇒ velká chyba

→ snížení σ_f pomocí vhodné váhové funkce

$w(x)$: $w(x) > 0 \wedge \int_a^b dx\, w = 1$,

která je "podobná" f ⇔ $\frac{f}{w} \approx$ konst.

$$I = \int_a^b dx\, f = \int_a^b dx\, \frac{f}{w} w = \int_0^1 dy\, g(y) \approx \frac{1}{N} \sum_j^N g(\underset{\uparrow}{y_j}),$$

kde $y(x) = \int_a^x dt\, w(t)$

$dy = w\, dx$ $\qquad g(y) = \frac{f(x(y))}{w(x(y))}$

y_j → náhodná veličina s rovnoměrným rozdělením na $[0,1]$

⇒ musím umět invertovat CDF $x = x(y)$

→ pokud neumím invertovat CDF, můžu použít:

$I \approx \frac{1}{N} \sum_j \frac{f(x_j)}{w(x_j)}$ ← x_j náhodná proměnná s rozdělením $w(x)$ na $[a,b]$

Přesnost integračních metod

→ metoda řádu $O(1/n^k)$ v d-dimenzích, celkem bodů $N = n^d$

⇒ přesnost $O(N^{-k/d})$

→ MC metoda : $O(N^{-1/2})$

$\Rightarrow$ srovnatelné pro $d = 2k$

Generování pseudonáhodných čísel s daným rozdělením

→ máme uniformní náhodnou proměnnou na $[0,1]$ a chceme generovat čísla s jiným rozdělením

Inverze distribuční funkce

→ chci generovat x s rozdělením $\rho(x)$

$$F(x) \equiv \mathbb{P}(X<x) = \int_{-\infty}^{x} dt\, \rho(t),$$

pak jednoduše: $x_i = F^{-1}(\xi_i)$, kde ξ_i je uniformní

př.: exp rozdělení

$$\rho(x) = \lambda e^{-\lambda x} \Rightarrow F(x) = \int_0^x \lambda e^{-\lambda t}\, dt = 1 - e^{-\lambda x}$$

$$\Rightarrow x = F^{-1}(\xi_i) = -\frac{1}{\lambda} \ln \xi_i$$

trik $1-\xi_i = \xi_i'$

př. rozdělení na sféře

$$dS = r^2 \sin\vartheta\, dr\, d\vartheta\, d\varphi \Rightarrow \rho(\vartheta,\varphi) = \frac{\sin\vartheta}{4\pi}$$

✓ normalizace

$$F(\vartheta,\varphi) = \frac{\varphi}{2\pi}\, \frac{1-\cos\vartheta}{2}$$

$$\Rightarrow (\vartheta_i, \varphi_i) = \left(\arccos(1-2\xi_i),\ 2\pi \chi_i\right)$$

př.: normální rozdělení

→ Erf nelze invertovat, trik ve 2D

$x_i = r_i \cos\varphi_i$ $\qquad r_i = \sqrt{-2\ln \xi_i}$

$y_i = r_i \sin\varphi_i$ $\qquad \varphi_i = 2\pi \chi_i$

Von Neumannova metoda

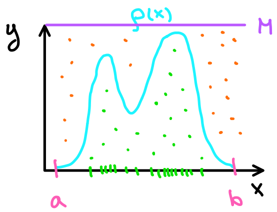

```
vygeneruj $\xi_i, \eta_i \in [0,1]$
$x_i = a + (b-a)\xi_i$
$y_i = M\eta_i$
pokud $y_i \le \rho(x_i)$
    přijmi
jinak
    cycle
```

Metropolis-Hastingsův algoritmus

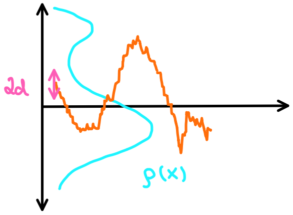

```
r = random()
xtrial = x + d(2r - 1)
ratio = ρ(xtrial) / ρ(x)
if radio ≥ 1 or ratio ≥ random()
    x = xtrial
return x
```

→ funguje i ve více dimenzích

→ má vyšší korelaci

→ proč funguje v limitě dlouhé procházky?

$N_n(x)$ … hustota nezávislých chodců, kteří vyrazili náhodně po n krocích

$$\Delta N_n(x) = N_n(y)P(y \to x) - N_n(x)P(x \to y)$$

v ustáleném stavu

$$= N_n(y)\, P(x\to y)\left[\frac{P(y\to x)}{P(x\to y)} - \frac{N_n(x)}{N_y(x)}\right] \approx 0$$

$$\frac{P(y\to x)}{P(x\to y)} = \frac{\cancel{T(y\to x)}\, A(y\to x)}{\cancel{T(x\to y)}\, A(x\to y)} = \frac{\rho(x)}{\rho(y)}$$

pravděpodobnosti vykrácení

$$A(x\to y) = \begin{cases} 1 & \rho(x) \geq \rho(y) \\ \frac{\rho(y)}{\rho(x)} & \text{jinak} \end{cases} \qquad A(y\to x) = \begin{cases} \frac{\rho(x)}{\rho(y)} & \rho(x) \geq \rho(y) \\ 1 & \text{jinak} \end{cases}$$

Aplikace metod MC

Termodynamické MC

→ výpočet středních hodnot TD veličin systému pomocí MC

- založeno na ergodické hypotéze ≡ průměrování přes fázový prostor

$$\langle X\rangle = \int d^{3N}p\, d^{3N}q\;\; X(p,q)\;\; \underbrace{\rho(p,q)}_{\text{hustota pravděpodobnosti ve fázovém prostoru}}$$

→ nejčastěji používáme pro kanonický systém:

$$\rho(q,p;N,V,T) = \frac{1}{Z_c}\, e^{-\beta H(p,q)}$$

- pokud máme systém identických částic a Hamiltonián je ve tvaru

$$H(p,q) = K(p) + V(q),$$

pak lze vyintegrovat přes hybnosti

$$\langle X\rangle = \frac{1}{Q_{NVT}} \int d^{3N}q \, X(q)\, e^{-\beta V(q)} ,$$

kde $$Q_{NVT} = \int d^{3N} e^{-\beta V(q)}$$

→ v MC aproximujeme

$$\langle X\rangle \approx \frac{1}{N_{MC}} \sum_{j=1}^{N_{MC}} X(\sigma_j)$$

konfigurace

σ_i jsou náhodné konfigurace s $\rho(\sigma_i) \propto e^{-\beta H(\sigma_j)}$

→ výhodné je použít Metropolisův algoritmus

- preferenčně vybírá ty konfigurace, které nejvíce přispívají do střední hodnoty
- není potřeba znát normalizační partiční sumou, používáme jen podíl

$$\frac{\rho(\sigma_{trial})}{\rho(\sigma_k)} = \frac{\frac{1}{Z} e^{-\beta H(\sigma_{trial})}}{\frac{1}{Z} e^{-\beta(\sigma_k)}} = e^{-\beta \Delta E}$$

→ pokud $\Delta E > 0$ ⇒ číslo v int. $(0,1)$ ⇒ $e^{-\beta \Delta E} \overset{?}{>}$ random

→ pokud $\Delta E \leq 0$ ⇒ bereme 1 ⇒ akceptujeme

Simulace TD systému pomocí MC

1) inicializace ≡ vygenerujeme náhodnou počáteční konfiguraci s "rozumnou" E

2) termalizace ≡ několik kroků M-H algoritmu, abychom se dostali do rozumné oblasti

3) měření ≡ generujeme M-H kroky a určujeme veličiny in question, můžeme měřit až např. po 10 krocích, nebo provádíme sweepy

4) průměrování ≡ zprůměrování hodnot z kroků + průměrování z různých počátečních konfigurací

Geometrické MC – perkolace

→ studium počtu klastrů a jejich vlastností v "náhodných" strukturách

→ modelujeme reálný systém na specifické mřížce v d-dimenzionálním prostoru

→ mřížky můžeme obsazovat
- pozice (site percolation)
- vazby (bond percolation)

→ počet obsazených míst závisí na stavovém parametru – obsazovací pravděpodobnosti p – a je náhodný
- obvykle se uvažuje nezávislá pro jednotlivá místa

Práh perkolace p_c ≡ obsazovací pravděpodobnost, při které se objeví spanning cluster

- pro nekonečnou mřížku je vždy pro $p > p_c$, ale nikdy pro $p < p_c$
- více sousedů => snazší propojit => nižší p_c

Hoshen-Kopelmanův algoritmus

- umožňuje najít všechny clustery na jeden průchod

1) systematicky projdi všechny body mřížky

2) přiřaď obsazenému místo číslo klasteru
   - a) číslo klasteru obsazeného souseda
   - b) nové číslo

3) vyřeš konflikty, pokud dva sousední body připadají různým clusterům
   - → využijeme pomocné pole
   - přiřazujeme menší číslo při konfliktu
   - je nutné měnit všechna čísla při přečíslování

Geometrické MC – difúzí limitovaná agregace

→ generování komplexních struktur pomocí jednoduchých pravidel

→ růst systému je modelován posloupností náhodných stavů

→ pro porovnání modelu s realitou je potřeba určit veličiny zachycující charakter komplexní struktury

např.: fraktální dimenze $D_f \simeq \dfrac{\log N(a)}{\log L(a)}$

- $N(a)$ = počet částic ve čtverci (krychli) o straně a
- $L(a)$ = počet míst mřížky, která tvoří tuto stranu

Základní algoritmus DLA

1) inicializace → nastavení "semínek" → obsazení jednoho nebo více míst

2) opakuj následující kroky, dokud není struktura dostatečně velká

a) vypuštění nové částice např. na kružnici o poloměru $R_{start} > R_{max}$, kde R_{max} je aktuální max. vzdálenost agregované struktury

→ R_{start} v průběhu měnit, např. $R_{start} = R_{max} + 1$

b) difúzní pohyb ≡ náhodná procházka po mřížce, dokud není sousední místo obsazené, nebo $R > R_{kill}$

- pro větší efektivitu lze náhodně procházet jen pro $R < R_{jump}$, pro $R > R_{jump}$ provádíme skoky náhodně po kružnicích s $r = R - R_{start}$

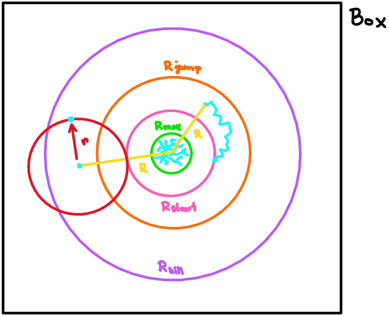c) agregace ≡ pokud je sousední místo obsazené, tak se částice agreguje