

1. Monte Carlo

Statistický úvod

→ náhodná veličina X s $\langle X \rangle = a$ $\langle \Delta X^2 \rangle = b^2$

→ uvažujeme aditivní proměnnou na systému:

$$A(x) = \sum_j X_j$$

$\uparrow$ identické pozorovatelné $X_j \equiv X$

→ statistika pozorovatelné A :

$$\langle A \rangle = \langle \sum_j X_j \rangle = \sum_j \langle X_j \rangle = N \langle X \rangle = Na$$

nezávislost *identické*

• korelace

$$\langle X_j X_k \rangle = \begin{cases} \langle X_j^2 \rangle & j=k \\ \langle X_j \rangle \langle X_k \rangle & j \neq k \end{cases}$$

nezávislost

• rozptyl

$$\langle (\Delta A)^2 \rangle = \langle \sum_j \Delta X_j \Delta X_j \rangle = \sum_j \langle \Delta X_j^2 \rangle = N \langle \Delta X^2 \rangle = Nb^2$$

$$\Rightarrow \sigma_N \propto \sqrt{N}$$

protože $\langle \Delta X_i \Delta X_j \rangle = \langle X_i X_j \rangle - \langle X_i \rangle \langle X_j \rangle$

Zákon velkých čísel

→ zejména se o průměr $\leftrightarrow$ intenzivní veličinu, hustotu

$$\bar{A} := \frac{A}{N}$$

• střední hodnota: $\langle \bar{A} \rangle = \frac{1}{N} \langle A \rangle = \langle X \rangle = a$

• rozptyl: $\langle (\Delta \bar{A})^2 \rangle = \frac{1}{N^2} \langle (\Delta A)^2 \rangle = \frac{b^2}{N} \xrightarrow{N \rightarrow \infty} 0$


Centrální limitní věta

→ chování distribuce pro velká N

$$\hookrightarrow \sigma \propto \sqrt{N}$$

$\Rightarrow$ zkoumáme chování okolo střední hodnoty přeskálování

tak, aby rozdělení pro různá N měla stejný rozptyl



$$\rightarrow Y := \frac{A - N \langle X \rangle}{\sqrt{N}}$$

→ pro charakteristickou funkci máme:

$$\phi_Y(t) = \langle e^{itY} \rangle = \langle e^{i \frac{t}{\sqrt{N}} \sum_j (X_j - \langle X \rangle)} \rangle$$

$$= \langle e^{i \frac{t}{\sqrt{N}} \sum_j \Delta X_j} \rangle = \langle e^{i \frac{t}{\sqrt{N}} \Delta X} \rangle^N$$

nezávislost ΔA_j

$$= \left[1 - \frac{1}{2} \frac{t^2}{N} \langle \Delta X^2 \rangle + O\left(\frac{1}{N^{3/2}}\right) \right]^N$$

$$\xrightarrow{N \rightarrow \infty} e^{-\frac{t^2}{2} \frac{\langle \Delta X^2 \rangle}{b^2}}$$

charakteristická funkce normálního rozdělení s $\mu=0$

$\hookrightarrow$ neuvolňujeme pouze druhý kumulant

→ Centrální limitní věta:

$$Y(N) \xrightarrow{N \rightarrow \infty} \text{normální rozdělení}$$

$$\mathcal{P}(y) = \frac{1}{\sqrt{2\pi b^2}} e^{-\frac{y^2}{2b^2}}$$

$$\Rightarrow A \approx N \langle X \rangle + \sqrt{N} \mathcal{N}(0, b^2)$$

Odhad chyby MC

$\Rightarrow$ průměr N nezávislých náhodných veličin dá rozdělení:

$$\bar{A} = \frac{1}{N} \sum_j X_j \Rightarrow \langle \bar{A} \rangle = \langle X \rangle = a$$

$$\langle \Delta \bar{A}^2 \rangle = \frac{1}{N} \langle \Delta X^2 \rangle = \frac{b^2}{N}$$

$$\text{a tedy směrodatná odchylka} \quad \sigma(\bar{A}_N) = \frac{b}{\sqrt{N}}$$

$$\rightarrow \mathbb{P}(|\bar{A}_N - a| \leq 3\sigma) \approx 0.9973$$

$\sim \frac{1}{\sqrt{N}}$

$$\rightarrow \text{pravděpodobnostná chyba: } r \approx 0.67\sigma = 0.67 \frac{b}{\sqrt{N}}$$

$\hookrightarrow$ náhodná veličina je s pravděpodobností 1/2 v intervalu $|\bar{A}_N - a| \leq r$

→ není to hlavní odhad chyby, ale pravděpodobnostná chyba


$\Rightarrow$ chyba může být větší, ale pravděpodobnost toho je malá

Integrace metodou MC - prosté vzorkování

náhodná proměnná na $[a,b]$ s rovnoměrným rozdělením

$$I = \int_a^b dx f \approx \frac{b-a}{N} \sum_j f(x_j)$$

míra na $[a,b]$



→ nahrazení na integrál jako na průměrnou funkci přes interval

→ v d -dim. prostoru

$$I = \int_{\Omega} d^d x f(x_1, \dots, x_d) \approx \frac{|\Omega|}{N} \sum_j f(x_1^j, \dots, x_d^j)$$

$$\rightarrow \text{odhad chyby: } r \approx 0.67 \sigma_f \approx 0.67 \frac{b-a}{\sqrt{N}} \sigma_f$$

kde varianci funkce f lze odhadnout za běhu:

$$\sigma_f^2 = \langle f^2 \rangle - \langle f \rangle^2 \approx \frac{1}{N} \sum_j f^2(x_j) - \left[\frac{1}{N} \sum_j f(x_j) \right]^2$$

Integrace metodou MC - preferenzi vzorkování

→ chyba závisí na $\sigma_f \Rightarrow$ pokud je f téměř konstantní,

pak malá, naopak pokud σ_f velká $\Rightarrow$ větší chyba

→ snížení σ_f pomocí vhodné váhové funkce

$$w(x) : w(x) > 0 \quad \wedge \quad \int_a^b dx w = 1,$$

kteří je "podobná" $f \Leftrightarrow \frac{f}{w} \approx \text{konst.}$

$$I = \int_a^b dx f = \int_a^b dx \frac{f}{w} w = \int_0^1 dy g(y) \approx \frac{1}{N} \sum_j g(y_j)$$

$\uparrow$

$$\text{kde } y(x) = \int_a^x dt w(t)$$

$$dy = w dx \quad g(y) = \frac{f(x(y))}{w(x(y))}$$

$y_j \rightarrow$ náhodná veličina s rovnoměrným rozdělením na $[0,1]$

$\Rightarrow$ musíme umět invertovat CDF $x = x(y)$

→ pokud neumíme invertovat CDF, můžeme pozít:

$$I \approx \frac{1}{N} \sum_j \frac{f(x_j)}{w(x_j)} \leftarrow x_j \text{ náhodně proměnná s rozdělením } w(x) \text{ na } [a,b]$$

Porovnání přesnosti integračních metod

→ metoda řádu $O(1/n^k)$ v d -dimenzích, celkem bodů $N = n^d$

$$\Rightarrow \text{přesnost } O(N^{-k/d})$$

→ MC metoda: $O(N^{-1/2})$

$$\Rightarrow \text{svazitelní pro } d = 2k$$

Generování pseudonáhodných čísel s daným rozdělením

→ máme uniformní náhodnou proměnnou na $[0,1]$ a chceme

generovat čísla s jiným rozdělením

Inverze distribuční funkce

→ chceme generovat x s rozdělením $\mathcal{P}(x)$

$$F(x) \equiv \mathbb{P}(X < x) = \int_{-\infty}^x dt \mathcal{P}(t)$$

pak jednoduše: $x_i = F^{-1}(\xi_i)$, kde ξ_i je uniformní

př.: exp rozdělení

$$\mathcal{P}(x) = \lambda e^{-\lambda x} \Rightarrow F(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}$$

$$\Rightarrow x = F^{-1}(\xi) = -\frac{1}{\lambda} \ln \xi$$

trik $1 - \xi = \xi'$

př.: rozdělení na sféře

$$dS = r^2 \sin \vartheta dr d\vartheta d\varphi \Rightarrow \mathcal{P}(\vartheta, \varphi) = \frac{\sin \vartheta}{4\pi}$$

normalizace

$$F(\vartheta, \varphi) = \frac{\varphi}{2\pi} \frac{1 - \cos \vartheta}{2}$$

$$\Rightarrow (\vartheta_i, \varphi_i) = \left(\arccos(1 - 2\xi_i), 2\pi \chi_i \right)$$

př.: normální rozdělení

→ Err nelze invertovat, trik ve 2D

$$x_i = \eta_i \cos \varphi_i \quad r_i = \sqrt{-2 \ln \xi_i}$$

$$y_i = \eta_i \sin \varphi_i \quad \varphi_i = 2\pi \chi_i$$

von Neumannova metoda

vygeneruj $\xi_i, \eta_i \in [0,1]$

$$x_i = a + (b-a) \xi_i$$

$$y_i = M \eta_i$$

pokud $y_i \leq \mathcal{P}(x_i)$

přijmí

jinak cycle

Metropolis-Hastings algoritmus

$r = \text{random}()$
 $x_{\text{trial}} = x + d(2r-1)$
 $\text{ratio} = \mathcal{P}(x_{\text{trial}}) / \mathcal{P}(x)$
if $\text{ratio} \geq 1$ or $\text{ratio} \geq \text{random}()$
 $x = x_{\text{trial}}$
return x

→ funguje i ve více dimenzích

→ má vyšetřovat korelaci

→ proč funguje v limitě dlouhých probíhů?

$N_n(x)$... hustota nezávislých dvojic, která vyhovuje vztahu po n krocích

$$\Delta N_n(x) = N_n(y) \mathcal{P}(y \rightarrow x) - N_n(x) \mathcal{P}(x \rightarrow y)$$

v ustáleném stavu

$$= N_n(y) \mathcal{P}(x \rightarrow y) \left[\frac{\mathcal{P}(y \rightarrow x)}{\mathcal{P}(x \rightarrow y)} - \frac{N_n(x)}{N_n(y)} \right] \approx 0$$

$$\frac{\mathcal{P}(y \rightarrow x)}{\mathcal{P}(x \rightarrow y)} = \frac{T(y \rightarrow x) A(y \rightarrow x)}{T(x \rightarrow y) A(x \rightarrow y)} = \frac{\mathcal{P}(x)}{\mathcal{P}(y)}$$

pravděpodobnosti vyložení

$$A(x \rightarrow y) = \begin{cases} 1 & \mathcal{P}(x) \geq \mathcal{P}(y) \\ \frac{\mathcal{P}(y)}{\mathcal{P}(x)} & \text{jinak} \end{cases} \quad A(y \rightarrow x) = \begin{cases} \frac{\mathcal{P}(x)}{\mathcal{P}(y)} & \mathcal{P}(x) \geq \mathcal{P}(y) \\ 1 & \text{jinak} \end{cases}$$