1. Monte Carlo

pátek 2. ledna 2026 10:13

1. Monte Carlo

Statistický úvod

→ náhodná veličina X s $\langle X \rangle = a$ $\langle \Delta X^2 \rangle = b^2$

→ uvažujme aditivní proměnnou na systému:

$$A(X) = \sum_j X_j$$

$\uparrow$ identické pozorovatelné $X_j \equiv X$

→ statistika pozorovatelné A:

$$\langle A \rangle = \left\langle \sum_j X_j \right\rangle \underset{\text{nezávislost}}{=} \sum_j \langle X_j \rangle \underset{\text{identické}}{=} N \langle X \rangle = Na$$

- korelace

$$\langle X_j X_k \rangle \underset{\text{nezávislost}}{=} \begin{cases} \langle X_j^2 \rangle & j = k \\ \langle X_j \rangle \langle X_k \rangle & j \neq k \end{cases}$$

- rozptyl

$$\langle (\Delta A)^2 \rangle = \left\langle \sum_{ij} \Delta X_i \underset{\uparrow}{\Delta} X_j \right\rangle = \sum_j \langle \Delta X_j^2 \rangle = N \langle \Delta X \rangle = Nb^2$$

$\Rightarrow \quad \sigma_N \propto \sqrt{N}$ protože $\langle \Delta X_i \Delta X_j \rangle = \langle X_i X_j \rangle - \langle X_i \rangle \langle X_j \rangle$

Zákon velkých čísel

→ zajímáme se o průměr ↔ intenzivní veličinu, hustotu

$$\bar{A} := \frac{A}{N}$$

- střední hodnota: $\langle \bar{A} \rangle = \frac{1}{N} \langle A \rangle = \langle X \rangle = a$
- rozptyl: $\langle (\Delta \bar{A})^2 \rangle = \frac{1}{N^2} \langle (\Delta A)^2 \rangle = \frac{b^2}{N} \xrightarrow[N \to \infty]{} 0$

Centrální limitní věta

→ chování distribuce pro velká N

↳ $\sigma \propto \sqrt{N}$

⇒ zkoumáme chování okolo střední hodnoty přeškálování tak, aby rozdělení pro různá N měla stejný rozptyl

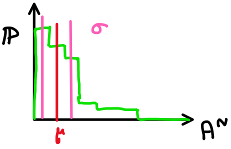

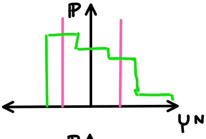

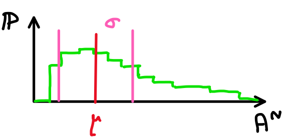

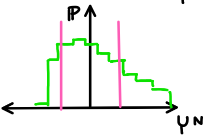

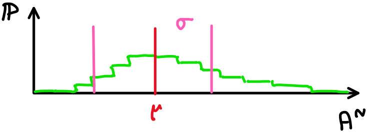

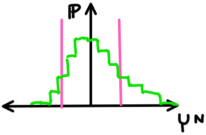

→ $$Y := \frac{A - N\langle X\rangle}{\sqrt{N}}$$

→ pro charakteristickou funkci máme :

$$\phi_Y(t) = \langle e^{itY}\rangle = \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j \underbrace{(X_j - \langle X\rangle)}_{\Delta A_j}}\right\rangle$$

$$= \left\langle e^{i\frac{t}{\sqrt{N}}\sum_j \Delta X_j}\right\rangle \underset{\text{nezávislost}}{=} \left\langle e^{i\frac{t}{\sqrt{N}}\Delta X}\right\rangle^N$$

$$= \left[1 - \frac{1}{2}\frac{t^2}{N}\langle\Delta X^2\rangle + \mathcal{O}\left(\frac{1}{N^{3/2}}\right)\right]^N$$

$$\xrightarrow{N\to\infty} e^{-\frac{t^2}{2}\underbrace{\langle\Delta X^2\rangle}_{\sigma^2}}$$ ← charakteristická funkce normálního rozdělení s $\mu = 0$

↳ nenulový pouze druhý kumulant

→ Centrální limitní věta :

$$Y^{(N)} \xrightarrow[N\to\infty]{} \text{normální rozdělení}$$

$$\rho(y) = \frac{1}{\sqrt{2\pi\sigma^2}}\, e^{-\frac{y^2}{2\sigma^2}}$$

⇒ $$A \approx N\langle X\rangle + \sqrt{N}\,\mathcal{N}(0,\sigma^2)$$

Odhad chyby MC

⇒ průměr N nezávislých náhodných veličin dá rozdělení :

$$\bar{A} = \frac{1}{N}\sum_j X_j \Rightarrow \langle \bar{A} \rangle = \langle X \rangle = a$$

$$\langle \Delta \bar{A}^2 \rangle = \frac{1}{N}\langle \Delta X^2 \rangle = \frac{b^2}{N}$$

a tedy směrodatná odchylka $\sigma(A_N) = \frac{b}{\sqrt{N}}$

→ $\mathbb{P}\left(|\bar{A}_N - a| \leq 3\underset{\uparrow \sim \frac{1}{\sqrt{N}}}{\sigma} \right) \approx 0.9973$

→ pravděpodobnostná chyba: $r \approx 0.67\sigma = 0.67 \frac{b}{\sqrt{N}}$

↳ náhodná veličina je s pravděpodobností 1/2 v intervalu $|\bar{A}_N - a| \leq r$

→ není to horní odhad chyby, ale pravděpodobná chyba

⇒ chyba může být větší, ale pravděpodobnost toho je malá

Integrace metodou MC - prosté vzorkování

náhodná proměnná na [a,b]
s rovnoměrným rozdělením

$$I = \int_a^b dx\, f \approx \underbrace{\frac{b-a}{N}}_{\text{míra na } [a,b]} \sum_j^N f(\overset{\downarrow}{x_j})$$

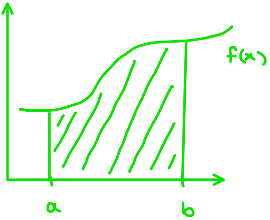

→ nahlížíme na integrál jako na průměrování funkce přes interval

→ v d-dim. prostoru

$$I = \int_\Omega d^d x\, f(x_1, \dots, x_d) \approx \frac{|\Omega|}{N} \sum_j^N f(x_1^j, \dots, x_d^j)$$

→ odhad chyby: $r \approx 0.67\,\sigma_I \approx 0.67\,\frac{b-a}{\sqrt{N}}\,\sigma_f$,

kde varianci funkce f lze odhadnout za běhu:

$$\sigma_f^2 = \langle f^2 \rangle - \langle f \rangle^2 \approx \frac{1}{N}\sum_j^N f^2(x_j) - \left[\frac{1}{N}\sum_j^N f(x_j)\right]^2$$

Integrace metodou MC – preferenční vzorkování

→ chyba závisí na σ_f ⇒ pokud je f téměř konstantní, pak malá, naopak pokud σ_f velké ⇒ velká chyba

→ snížení σ_f pomocí vhodné váhové funkce

$w(x)$: $w(x) > 0 \wedge \int_a^b dx\, w = 1$,

která je "podobná" f ⇔ $\frac{f}{w} \approx$ konst.

$$I = \int_a^b dx\, f = \int_a^b dx\, \frac{f}{w}\, w = \int_0^1 dy\, g(y) \approx \frac{1}{N}\sum_j^N g(\underset{\uparrow}{y_j}),$$

kde $y(x) = \int_a^x dt\, w(t)$

$dy = w\,dx$ $\qquad g(y) = \frac{f(x(y))}{w(x(y))}$

y_j → náhodná veličina s rovnoměrným rozdělením na $[0,1]$

⇒ musím umět invertovat CDF $x = x(y)$

→ pokud neumím invertovat CDF, můžu použít:

$$I \approx \frac{1}{N}\sum_j \frac{f(x_j)}{W(x_j)}$$ ← x_j náhodná proměnná s rozdělením $W(x)$ na $[a,b]$

Porovnání přesnosti integračních metod

→ metoda řádu $O(1/n^k)$ v d-dimenzích, celkem bodů $N = n^d$

⇒ přesnost $O(N^{-k/d})$

→ MC metoda: $O(N^{-1/2})$

⇒ srovnatelné pro $d = 2k$

Generování pseudonáhodných čísel s daným rozdělením

→ máme uniformní náhodnou proměnnou na $[0,1]$ a chceme generovat čísla s jiným rozdělením

Inverze distribuční funkce

→ chci generovat x s rozdělením $\rho(x)$

$$F(x) \equiv \mathbb{P}(X < x) = \int_{-\infty}^{x} dt\, \rho(t),$$

pak jednoduše: $x_i = F^{-1}(\xi_i)$, kde ξ_i je uniformní

př.: exp rozdělení

$$\rho(x) = \lambda e^{-\lambda x} \Rightarrow F(x) = \int_0^x \lambda e^{-\lambda t}\, dt = 1 - e^{-\lambda x}$$

$$\Rightarrow x = F^{-1}(\xi_i) = -\frac{1}{\lambda}\ln \xi_i$$

trik $1 - \xi_i = \xi_i'$

př. rozdělení na sféře

$$dS = r^2 \sin\vartheta \, dr \, d\vartheta \, d\varphi \Rightarrow \rho(\vartheta,\varphi) = \frac{\sin\vartheta}{4\pi} \checkmark$$ normalizace

$$F(\vartheta,\varphi) = \frac{\varphi}{2\pi} \frac{1-\cos\vartheta}{2}$$

$$\Rightarrow \quad (\vartheta_i, \varphi_i) = \left(\arccos(1-2\xi_i) , 2\pi \chi_i \right)$$

př.: normální rozdělení

→ Erf nelze invertovat, trik ve 2D

$x_i = r_i \cos\varphi_i$ $\qquad r_i = \sqrt{-2\ln\xi_i}$

$y_i = r_i \sin\varphi_i$ $\qquad \varphi_i = 2\pi\chi_i$

von Neumannova metoda

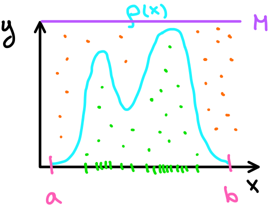

vygeneruj $\xi_i, \eta_i \in [0,1]$

$x_i = a + (b-a)\xi_i$

$y_i = M \eta_i$

pokud $y_i \le \rho(x_i)$

přijmi

jinak

cycle

Metropolis-Hastigs algoritmus

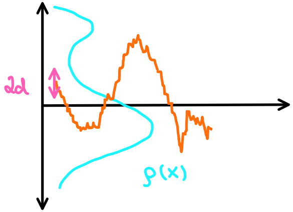

```
r = random()
xtrial = x + d(2r - 1)
ratio = ρ(xtrial) / ρ(x)
if radio ≥ 1 or ratio ≥ random()
    x = xtrial
return x
```

- → funguje i ve více dimenzích
- → má vyšší korelaci

- → proč funguje v limitě dlouhé procházky?

$N_n(x)$ … hustota nezávislých chodců, kteří vyrazili náhodně po n krocích

$$\Delta N_n(x) = N_n(y)\,P(y\to x) - N_n(x)\,P(x\to y)$$

v ustáleném stavu

$$= N_n(y)\,P(x\to y)\left[\frac{P(y\to x)}{P(x\to y)} - \frac{N_n(x)}{N_y(x)}\right] \approx 0$$

$$\frac{P(y\to x)}{P(x\to y)} = \frac{\cancel{T(y\to x)}\,A(y\to x)}{\cancel{T(x\to y)}\,A(x\to y)} = \frac{\rho(x)}{\rho(y)}$$

pravděpodobnosti vykročení

$$A(x\to y) = \begin{cases} 1 & \rho(x) \geq \rho(y) \\ \frac{\rho(y)}{\rho(x)} & \text{jinak} \end{cases} \qquad A(y\to x) = \begin{cases} \frac{\rho(x)}{\rho(y)} & \rho(x) \geq \rho(y) \\ 1 & \text{jinak} \end{cases}$$